ArmaganBranch · b8859ca

Öğrenci 2 ne yaptı?

İki model. Neyi neden seçtim. Ne çıktı.

Öğrenci 1 ve Öğrenci 3 için. Kod üstte, çıktı altta.

Benim işim ne?

Perceptron ve LightGBM. Ayarla, karşılaştır, teste bir kez tahmin et. Notebook: `03_perceptron_lgbm`.

0,699
LightGBM test Macro-F1

0,552
LightGBM test PR-AUC

0,617
Perceptron test Macro-F1

50
Optuna denemesi, 30'u erken kesildi

Veri: Öğrenci 1'in **clean** seti. Bütün seçimler val'de. Test en sonda, tek sefer.

1. Taban
Dummy ile alt sınır

2. Perceptron
50 ayar × 5 tohum

3. LightGBM
5-fold CV, early stopping

4. Optuna
50 deneme, PR-AUC

5. Final
Train seti seç, teste tahmin

Önce taban: hiç bakmayan model

DummyClassifier özelliklere bakmaz. Gerçek model bunu açık farkla geçmeli.

Kod • 03, hücre 6

```
for strategy in ("most_frequent", "stratified"):
    dummy = DummyClassifier(strategy=strategy, random_state=SEED).fit(X_train, y_train)
    y_score = dummy.predict_proba(X_val)[:, 1]
    results[f"dummy_{strategy}"] = evaluate(y_val, y_score, dummy.predict(X_val))
```

Çıktı • val

model	macro_f1	roc_auc	pr_auc	accuracy
most_frequent (herkese "öder")	0.4378	0.5000	0.2211	0.7789
stratified (%22 ihtimalle "ödemez")	0.5019	0.5019	0.2218	0.6578

Herkese "öder" de: accuracy %77,9, ama tek borçlu yakalanmaz. Accuracy'ye bakan yanlış modeli seçer.
Hedef çizgi: **Macro-F1 0,50** ve **PR-AUC 0,22**'nin belirgin üstü.

Perceptron: 50 ayar, her biri 5 kez

Perceptron tek bir düz çizgi çizer. Yanlış bildiği satırda ağırlığı düzeltir. Olasılık vermez, ham skor kullanılır.

Kod • 03, hücre 9 (kısa)

```
def make_perceptron(seed: int = SEED, **params) → Pipeline:
    params = {"max_iter": 1000} | params
    return make_pipeline(make_preprocessor("linear"), Perceptron(random_state=seed, **params))
for eta0, penalty, alpha, class_weight in product(ETA0S, PENALTIES, ALPHAS, CLASS_WEIGHTS):
    for seed in SEEDS:
        model = make_perceptron(seed, **params).fit(X_train, y_train)
        rows.append(params | {"seed": seed, "n_iter": model[-1].n_iter_} | score_on_val(model))
```

Çıktı • 250 model, 6 dk • ilk 5 (5 tohum ortalaması)

eta0	penalty	alpha	class_weight	macro_f1	± std	pr_auc
0.001	**l2**	**0.001**	**none**	**0.6356**	**0.0303**	**0.4069**
0.01	elasticnet	0.001	balanced	0.6312	0.0324	0.3853
0.01	l2	0.0001	none	0.6281	0.0184	0.4032
0.1	elasticnet	0.001	balanced	0.6236	0.0656	0.3806
0.001	none	0.0001	none	0.6235	0.0350	0.3798

Pipeline: ölçekleyici sadece train'e fit edilir, kopya yok. Eşik val'de Macro-F1'e göre.

Neden 5 tohum?

Tohum = satırların karıştırılma sırası. Perceptron bu sıraya çok duyarlı. Tek tohumla seçmek, şanslı sırayı seçmek olur.

0,615–0,636
ilk 10 ayarın ortalaması

0,007–0,066
aynı ayarın tohumlar arası std'si

0,621
tek tohumla "kazanan" ayarın 5 tohum ortalaması

Ayarlar arası fark, gürültüden küçük. Yani tavanı parametre değil model belirliyor.

Seçilen
`l2`, `eta0=1e-3`, `alpha=1e-3`, `class_weight=None` → Macro-F1 0,636 ± 0,030, PR-AUC 0,407

class_weight="balanced"
Tutarlı kazanç yok. Eşik zaten val'de seçiliyor, dengesizliği eşik düzeltiyor.

Tavan
ROC-AUC 0,676. Öğrenci 1'in sabit LightGBM'i 0,777. Fark doğrusal olmayan ilişkiden.

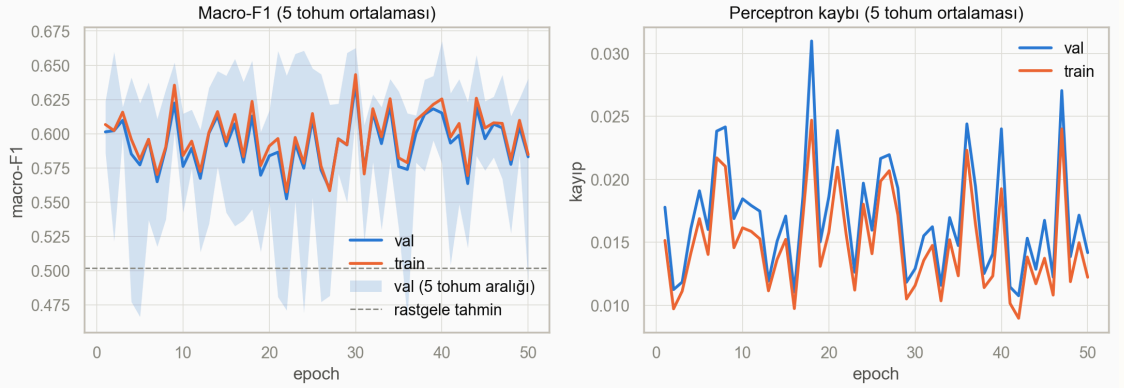
Öğrenme eğrisi: Perceptron nerede tıkanıyor?

Tur tur eğit, her turdan sonra train ve val'de ölç. 5 tohum × 50 tur.

Kod • 03, hücre 20 (kısa)

```
model = Perceptron(random_state=np.random.RandomState(seed), **PERCEPTRON_PARAMS)
for epoch in range(1, N_EPOCHS + 1):
    model.partial_fit(A_train, y_train, classes=np.array([0, 1]))
```

Çıktı • figures/extra_perceptron_curve.png



1. tur val: **0,601**

50. tur val: **0,583**

Öğrenme 1. turda bitiyor. Sonrası zikzak.

Train ≈ val: **ezber yok.**

Sorun: düz çizgi bu veriyi ayıramıyor (**underfitting**).

LightGBM: ağaçları sırayla ekle

Her yeni ağaç öncekilerin hatasını düzeltir. "PAY_0 ≥ 2 ise risk sıçrar" gibi eşikleri öğrenir. Perceptron öğrenemez.

Kod • 03, hücre 24 (kısa)

```
LGBM_FIXED = {"n_estimators": 2000, "metric": "average_precision", "random_state": SEED, "verbose": -1}

folds = StratifiedKFold(N_FOLDS, shuffle=True, random_state=SEED)
for fold, (fit_idx, stop_idx) in enumerate(folds.split(X, y)):
    model = LGBMClassifier(**(LGBM_FIXED | params)).fit(
        X.iloc[fit_idx], y.iloc[fit_idx], eval_X=X_stop, eval_y=y_stop,
        callbacks=[early_stopping(EARLY_STOP, verbose=False)],
    )
```

5-fold CV

Train 5 parçaya bölünür. Her parça bir kez sınav olur. Val'e hiç dokunulmaz.

Early stopping

2000 sadece tavan. 100 ağaç boyunca iyileşme yoksa dur, en iyi turu al.

PR-AUC

Model "ödemez" dediğinde ne kadar haklı? Dengesiz veride ROC-AUC'den dürüst.

Ölçekleme yok

Ağaç eşikle böler. 23 ham kolon olduğu gibi girer.

Ayar yapmadan bile LightGBM önde

Varsayılan parametreler. Fark ayardan değil, model ailesinden geliyor.

Çıktı • 03, hücre 28 • val

model	macro_f1	roc_auc	pr_auc
dummy_stratified	0.5019	0.5019	0.2218
perceptron (5 tohum ort.)	0.6356	0.6764	0.4069
lgbm (varsayılan, 59 ağaç)	**0.7071**	**0.7779**	**0.5534**

Çıktı • 03, hücre 26 • PAY_x kategorik mi, sayısal mı? (CV PR-AUC)

ayar	pr_auc	± std
hepsi sayısal	0.5630	0.0114
nominal kategorik, PAY_x sayısal (seçilen)	**0.5629**	**0.0114**
nominal + PAY_x kategorik	0.5605	0.0110

Üç ayar aynı. Anlamı doğru olan seçildi: SEX / EDUCATION / MARRIAGE sırasız, PAY_x sıralı (−2 → 8).
Öğrenci 1'in sabit LightGBM'i: 0,707 / 0,777. Örtüşüyor.

Optuna: 9 parametreyi akıllıca ara

Grid search imkânsız. TPE iyi denemelere bakıp yeni aday önerir. Kötü gideni MedianPruner erken keser.

Kod • 03, hücre 31 (kısa)

```
"num_leaves": trial.suggest_int("num_leaves", 15, 255, log=True),
"learning_rate": trial.suggest_float("learning_rate", 0.01, 0.2, log=True),
"max_depth": trial.suggest_int("max_depth", 3, 12) if limit_depth else -1,
"scale_pos_weight": trial.suggest_float("scale_pos_weight", 1.0, 4.0),   # + 5 parametre daha

study = optuna.create_study(
    storage=f"sqlite:///{OPTUNA_DB.as_posix()}", direction="maximize",
    sampler=optuna.samplers.TPESampler(seed=SEED),
    pruner=optuna.pruners.MedianPruner(n_startup_trials=5, n_warmup_steps=1),
)
```

TPE

Denemeleri "iyi" ve "kötü" diye ayırır. İyilerin bölgesinden yeni aday çeker. İlk 10 rastgele.

MedianPruner

Her fold'dan sonra bakar. Diğerlerinin medyanının altındaysa denemeyi keser.

Hedef: CV PR-AUC

Eşikten bağımsız. Eşik sonra val'de seçilir. Val aramaya karışmaz.

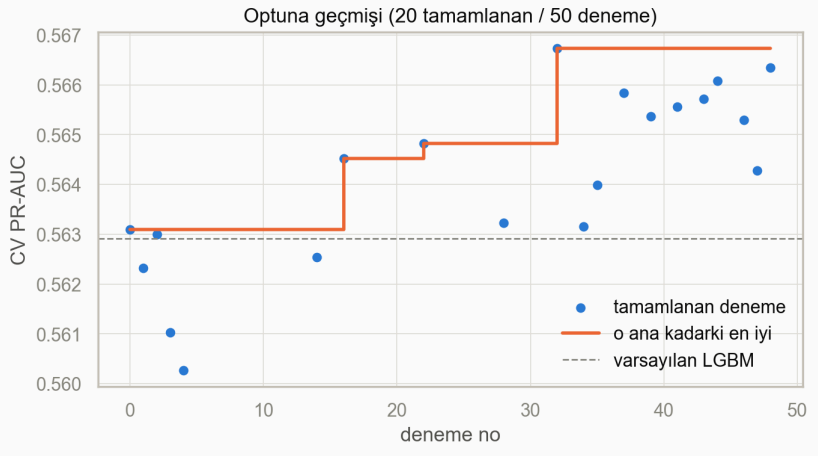
Optuna ne kazandırdı? Çok az.

En iyi deneme #32. Kazanç, fold'lar arası std'nin altında. Varsayılan LightGBM zaten tavana yakın.

Kod • 03, hücre 33 (kısa)

```
best = json.loads(BEST_LGBM_JSON.read_text(encoding="utf-8"))   # written from the study if missing
LGBM_PARAMS = suggest_lgbm(optuna.trial.FixedTrial(best["params"]))
LGBM_N_ESTIMATORS = best["best_iter"]
```

Çıktı • figures/extra_optuna_history.png



Varsayılan: **0,563** ± 0,011

Optuna #32: **0,567** ± 0,012

176 ağaç, learning_rate 0,017, num_leaves 66, subsample 0,58

`scale_pos_weight` ≈ 1: sınıf ağırlığına gerek yok

Val Macro-F1 0,707 → 0,711

Model neye bakıyor? gain mi, split mi?

split = o kolonla kaç kez bölündü. gain = o bölmeler ne kazandırdı. Modeli açıklamak için gain.

Kod • 03, hücre 38 (kısa)

```
importance = pd.DataFrame({
    "feature": tuned_lgbm.booster_.feature_name(),
    "gain": tuned_lgbm.booster_.feature_importance(importance_type="gain"),
    "split": tuned_lgbm.booster_.feature_importance(importance_type="split"),
})
```

Çıktı • ilk 6 (gain sırası)

feature	gain payı	split payı	split sırası
PAY_0	**0.3292**	**0.0263**	**15**
PAY_2	0.0883	0.0150	18
BILL_AMT1	0.0520	0.0839	1
LIMIT_BAL	0.0487	0.0715	2
PAY_AMT2	0.0453	0.0710	3
PAY_AMT1	0.0430	0.0660	4

PAY_0 gain'in üçte biri, ama split'te 15. Az bölünür, her bölme çok kazandırır. Para kolonları çok bölünür, az kazandırır.

BULDUĞUM TUZAKLAR · hepsi notebook'ta kanıtlı

Sessizce yanlış sonuç veren 4 yer

Perceptron: eta0 tek başına etkisiz

Görünen
eta0 değişince sonuç oynuyor → "etkili" sandık

Gerçek
Sabit 20 epoch'ta w / eta0 5 tohumda aynı. Oynama, `tol` mutlak olduğu için durma epoch'unun değişmesinden.

partial_fit hep aynı sırayı görüyor

Önce
`random_state=42`: her çağrıda üreteç baştan kurulur, her tur aynı karıştırma

Sonra
`np.random.RandomState(42)`: nesne ilerler, her tur yeni sıra

LightGBM negatif kategoriyi eksik sayar

Önce
PAY_x'teki −2 ve −1 (en bilgili kodlar) kategorik verilince NaN gibi okunur

Sonra
`pd.Categorical(X[col], categories=CAT_LEVELS[col])`: 0..k kodları, her split'te aynı

Pruner hiçbir denemeyi kesmiyordu

Önce
Fold skorlarının **ortalaması** raporlandı: ortalama düşer, en iyisi hep fold 0 → 50'de 0 kesme

Sonra
Toplam raporlandı: hep artar → 30/50 kesildi, 13 → 9 sn/deneme

Sentetik veri modele yarar mı?

Aynı parametre, 3 farklı train, sınav hep gerçek val. Artırılmış veride CV yok: sentetik satır doğduğu satırla ayrı fold'a düşer, skor şişer.

Kod • 03, hücre 41 (kısa)

```
# Balanced sets already fix the class ratio; weighting on top would correct it twice
lgbm_params = LGBM_PARAMS | ({} if variant == "clean" else {"scale_pos_weight": 1.0})
for seed in SEEDS:
    perceptron = make_perceptron(seed, **PERCEPTRON_PARAMS).fit(X_fit, y_fit)
    lgbm_on_val(lgbm_params | {"random_state": seed}, LGBM_N_ESTIMATORS, L_fit, y_fit)
```

Çıktı • gerçek val • 5 tohum ortalaması

model	train	macro_f1	± std	roc_auc	pr_auc
lgbm	**clean**	**0.7091**	**0.0013**	**0.7770**	**0.5502**
lgbm	smote	0.6947	0.0012	0.7611	0.5345
lgbm	ctgan	0.6892	0.0008	0.7626	0.5272
perceptron	**clean**	**0.6356**	**0.0303**	**0.6764**	**0.4069**
perceptron	smote	0.5665	0.0284	0.6073	0.2884
perceptron	ctgan	0.5843	0.0556	0.6242	0.3102

İki modelde de en iyi **clean**. Öğrenci 1'in sonucuyla aynı (0,707 → 0,698 / 0,689). Dengesizliği eşik zaten düzeltiyor.

Final: teste tek tahmin

clean ile eğit. Eşik val'de seç. Test ilk kez burada açılır, hiçbir seçim teste bakılarak yapılmaz.

Kod • 03, hücre 44 (kısa)

```
final_perceptron = make_perceptron(SEED, **PERCEPTRON_PARAMS).fit(X_train, y_train)
final_lgbm = LGBMClassifier(**(LGBM_FIXED | LGBM_PARAMS | {"n_estimators": LGBM_N_ESTIMATORS}))
for name, (val_score, test_score) in final_scores.items():
    threshold = pick_threshold(y_val, val_score)
    path = save_preds(name, test[ID_COL], y_test, test_score, threshold)
```

Çıktı • models/preds/{perceptron,lgbm}.csv, 4495 satır

model	split	macro_f1	roc_auc	pr_auc	eşik
lgbm	val	0.7113	0.7766	0.5517	0.3151
lgbm	**test**	**0.6986**	**0.7724**	**0.5522**	
perceptron	val	0.5935	0.6319	0.3110	-0.0003
perceptron	**test**	**0.6169**	**0.6473**	**0.3336**	

LightGBM'de PR-AUC val ≈ test: ezber yok. Perceptron'da `SEED=42` val'de 0,594 (5 tohum ort. 0,636). Tohumu val'e göre değiştirmedim: gürültüye göre seçmek olurdu.

Öğrenci 1'in istediği 3 iş: yapıldı

Commit `b8859ca`. Notebook baştan sona yeniden çalıştı, test tahminleri birebir aynı.

İş	Ne yaptım
En iyi Optuna parametresini JSON yaz	`models/best_lgbm_clean.json` (deneme #32). Final model bu dosyadan kurulur. Temiz klonda arama başka denemeyi bulsa da final değişmez, fark olursa uyarı basılır.
03'te nbqa black çalıştır	Uygulandı, `--check` temiz. Sadece biçim: uzun satırlar alt alta.
Yorumdaki std aralığını düzelt	"0,007–0,066" oldu. `perceptron_sweep.csv`'den yeniden hesapladım: 0,0068–0,0656.

E402'ye dokunmadım. Ayar Öğrenci 1'de.

Sonra ne olur?

Öğrenci 1'in sırasıyla aynı fikirdeyim. Benim dalım hazır.

1. Herkes
Kendi hatasını çözer

2. PR
ogrenci1/veri

3. PR
ArmaganBranch

4. PR
o3/kadirgonullu

5. Kontrol
Temiz klon, 00 → 05

Kim	Sonra
Öğrenci 2 (ben)	Sıra gelince PR. 01'i öğrenir, savunma provası.

Hata bulursan sahibine söyle. Başkasının dosyasına dokunma.